PCI 术后用药管理助手

——面向基层医生的 PCI 术后用药调整辅助系统

参赛队	呜呼呼
成员	王丝雨 高琳芳 郭浩阳
指导教师	范力宏 何颖
所属院校	西安交通大学
选题方向	AI 健康与生活服务——将 AI 技术应用于健康管理、生活服务等场景
作品形态	B/S Web 应用：Vue3 单页前端+FastAPI 服务端+大模型与检索增强能力

目录

1、项目概述 4

1.1、项目背景 4

1.2、要解决的问题 4

1.3、目标用户 5

1.4、建设成果 5

2、需求分析 6

2.1、医生画像与典型场景 6

2.2、业务流程 6

2.3、功能需求 6

2.4、非功能需求 7

2.5、关键约束 8

3、系统架构设计 8

3.1、总体架构 8

3.2、前端架构 8

3.3、服务端架构 9

3.4、数据模型 9

3.5、关键数据流 10

3.6、部署架构 10

4、AI 技术方案 11

4.1、动手前先定的四条原则 11

4.2、技术选型与理由 11

4.3、集成方式 13

4.4、优化策略 14

4.5、知识库与规则库建设 15
4.6、安全与合规 16
5、核心功能实现 17
5.1、结构化问诊表单 17
5.2、化验单拍照识别 17
5.3、规则引擎与结构化报告 17
5.4、结构化报告的排版与导出 18
5.5、摘录式指南问答 19
5.6、关键接口契约 19
6、测试与部署 20
6.1、测试策略与环境 20
6.2、功能测试 20
6.3、边界与安全测试 21
6.4、性能与稳定性 21
6.5、部署与运维 21
7、总结与展望 22
7.1、项目总结 22
7.2、创新点 22
7.3、局限性与风险 23
7.4、后续展望 24

1、项目概述

1.1、项目背景

经皮冠状动脉介入治疗（PCI）是冠心病血运重建的主要方式。根据国家心血管系统疾病医疗质量控制中心发布的《2025 年中国心血管病医疗质量概述》，2024 年全国 PCI 手术量达 224.3 万例，开展 PCI 的医院增至 3796 家，其中二级医院已从支架集采前的约 1200 家增至近 1700 家，手术可及性持续扩大。目前 PCI 手术仍主要在三级医院完成，但手术做完不等于治疗结束：术后以年为单位的二级预防，要靠患者回到居住地，在就近的县医院、社区卫生服务中心和乡镇卫生院完成复查与随访。手术集中在上级医院、长期管理落在基层，基层医生因此成了 PCI 术后患者随访期内打交道最多的医生。

PCI 术后的二级预防依赖长期、精确的药物治疗：以阿司匹林/吲哚布芬联合氯吡格雷/替格瑞洛构成的双联抗血小板治疗（DAPT）、以他汀为基础的强化降脂、β 受体阻滞剂、RAS 抑制剂，以及合并高血压、糖尿病、房颤时的协同用药。用药方案的每一次调整，都必须在两条相互矛盾的风险之间取值：降级或停用抗血小板药物会增加支架内血栓与心肌梗死风险，而延长强化抗栓又会增加消化道与颅内出血风险。急性冠脉综合征（ACS）与稳定性冠心病（慢性冠脉综合征，CCS）的二级预防方案在 DAPT 时长与降阶时机、β 受体阻滞剂与 ACEI/ARB 的适应证、LDL-C 目标值方面因临床情境而异。

真正的落差出现在出院之后。出院时，ACS 患者的阿司匹林等抗血小板药物使用率超过 90%，他汀超过 80%，但这个数字会随时间明显下滑：中国急性冠脉综合征临床路径研究（CPACS）显示，规律服用他汀的比例出院 3 个月还有 81.7%，1 年后只剩 59.4%；China PEACE 前瞻性研究显示，出院后 1 年内坚持按处方服药（依从性≥90%）的患者只占 52.9%。CCS 患者症状轻，对坚持服药的获益感受更弱，长期依从性往往更差。基层医生在十几分钟的门诊里，要同时核对手术信息、支架类型与数量、出院方案、近期化验、合并症和症状，再判断该不该减药、换药或转诊。这些判断散落在几十条推荐意见、多份指南文件里，靠门诊现场翻查根本来不及。于是常见三种结局：凭印象续方、一律不调整、或者直接让患者回上级医院。

本项目选题属于大赛推荐方向中的“AI 健康与生活服务”：把 AI 技术用在慢病随访这一具体、高频的健康管理场景上，聚焦 PCI 术后用药调整这个风险最高、最依赖指南知识的决策环节，而不是泛化的健康咨询。

1.2、要解决的问题

本项目要解决的不是医生缺少医学知识，而是知识到动作之间的转化缺口。

第一，信息不完整。基层随访时，手术日期、支架类型与枚数、出院抗栓方案常常缺失或口口相传。缺失信息下的任何激进调整都是高风险行为。

第二，推理链路过长。一次用药调整需要联合判断：术后时长是否仍在 DAPT 窗口期内、缺血与出血风险谁占优、合并症（房颤、消化道溃疡史、慢性肾脏病、肝功能异常）如何影响药物选择、化验值是否触发危急值、症状是否属于红旗征。这些判断在指南中是分散的，在基层医生的头脑中必须是串行的。

第三，输出不可执行。即便得出结论，医生需要的是今天做什么、两周内做什么、长期怎么管，以及依据哪一条指南。一段泛泛的科普文字无法进入病历，

也无法交班。

第四，大模型不可直接信任。医疗场景对幻觉的容忍度为零。让模型自由生成用药建议，等于把责任边界模糊化，这在基层是不可接受的。

这四条合在一起，基本框定了系统的形态：补齐缺失的信息、把分散的推理固化为规则、输出可归档可交班的行动清单、模型说的每句话都能落回指南原文。

1.3、目标用户

目标主要用户是县域医共体、二级医院与基层医疗卫生机构的执业医师，他们是 PCI 术后患者随访的主要接诊者，术后 12 个月内决策最密集。进入长期维持期后，系统的长期二级预防评估与指南问答仍然可用，DAPT 规则对超窗患者同样给出降阶提示。次要用户包括两类：一是上级医院负责下转的专科医师，以及需要理解用药方案的随访护士；二是通过远程会诊为跨省、异地居住患者提供用药指导的专科医师。这类患者无法回到手术医院复诊，当地医生又缺少手术原始资料，是目前随访链条上最薄弱的一环。

对医生来说，价值在于不必在门诊现场翻指南、凭记忆做权衡，能直接拿到一份两分钟生成、逐条可溯源、可直接打印归档的结构化报告。

系统的技术骨架由三部分构成：指南知识结构化与规则引擎承担决策判断，检索增强保证每一条建议可溯源至指南原文，大模型负责自然语言交互与个体化解释。

系统的定位是辅助决策而非替代决策：输出的始终是供医生审核的用药建议，而不是直接下达的医嘱。所有结论以指南原文与规则编号为依据，医师保留最终判断权。信息不足时系统不下结论，而是输出《信息补全清单》。

1.4、建设成果

当前版本已完成从信息采集、智能录入、规则推理到报告输出的完整闭环，并在公网稳定运行。

序号	成果	说明
1	结构化问诊表单	三大分组、7 项核心必填、13 项检查指标，含条件必填与跨字段校验
2	化验单拍照识别	手机拍照/多图上传，视觉大模型抽取结构化字段，逐张识别、冲突消解、确认回填
3	规则引擎与结构化报告	14 个字段组按 8 个固定部分组织、双风险轴、三级时限行动清单、指南编号溯源、信息缺口清单
4	摘录式指南问答	流式输出，答案只摘录指南原文并标注来源与证据等级，不自由发挥
5	报告与导出	打印样式一键转 PDF；草稿自动保存与版本迁移
6	公网演示环境	单端口集成环境：前后端同源部署于 8000 端口，无需额外安装客户端，评委可在演示机或局域网内直接体验。

2、需求分析

2.1、医生画像与典型场景

主要画像：基层全科医生，特征是对冠心病长期管理熟悉，但对 PCI 术式的细节（支架类型、病变支数、DAPT 时限分层）与最新指南更新不敏感；习惯使用纸质记录与院内 HIS；愿意接受工具辅助，但拒绝要花十分钟填表的系统。

次要画像：下转随访护士。负责按上级医院下转单核对用药，需要明确哪些差异是医生有意调整、哪些是患者自行停药。

典型场景四个，覆盖信息完整与信息缺失两种输入形态。

场景一：术后首次基层随访（术后 1 个月）。理想情况下患者带来出院小结与一叠化验单；现实中更常见的是只记得“放过两个支架”、出院小结没带等等。医生需要确认 DAPT 是否在窗口期内、他汀剂量与 LDL-C 是否达标、血压心率是否受控，并预约下次复查，前提是先把缺失的信息补齐或显式标记出来。

场景二：DAPT 窗口关闭的降阶评估（术后 6-12 个月）。这是随访周期内最关键的一次决策：双联抗血小板能否降为单药、保留阿司匹林还是 P2Y12 抑制剂、降阶后出血风险是否可承受。判断需要同时调用手术信息、缺血/出血分层与近期化验结果，是规则引擎的主战场。

场景三：症状驱动的临时就诊（任意时点）。患者主诉牙龈出血、黑便、乏力或胸闷加重。医生需要在出血与缺血之间重新权衡，判断是否需要停药、换药或立即转诊。

场景四：多病共存患者的方案冲突（任意时点）。患者合并房颤需口服抗凝、合并消化道溃疡史，形成三联抗栓与共病管理问题。

2.2、业务流程

系统把一次随访拆成五个前后衔接的任务节点。

节点	医生动作	系统支撑	完成判据
①信息采集	填写或拍照识别	分组表单、条件必填、草稿自动保存	7 项核心字段齐全
②数据校验	核对识别结果	字段回填、多图冲突提示、值域校验	无未处理冲突
③结构化分析	点击“确认无误，开始分析”	规则引擎生成报告	报告返回并渲染
④决策执行	阅读行动清单、调整处方	三级优先级、依据与时限	生成处置动作
⑤归档	导出 PDF	打印样式、免责声明	报告归档

在节点③的结构化分析中，系统不调用大模型参与判断。节点④之后，医生可以用指南问答追问依据。

2.3、功能需求

编号	模块	需求描述	优先级
FR-01	患者基本信息	年龄、性别、PCI 手术日期、出院诊断、病变支数、干预血管与干预方式	高

FR-02	合并症与既往史	高血压、糖尿病、房颤、心衰、CKD、肝功能异常、既往心梗/脑梗、出血史、药物不耐受与禁忌	高
FR-03	辅助检查	血常规、凝血、心肌酶、电解质、血脂、血糖、BNP、心电图、超声心动图	高
FR-04	当前用药	抗血小板、抗凝、β阻滞剂、RAS 抑制剂、降脂、降糖、PPI、CCB 等；出院时用药方案与当前用药方案双记录	高
FR-05	症状与用药行为	红旗症状分级、停药/漏服记录、临时用药、拟行手术等	高
FR-06	化验单识别	多图上传、逐张识别、结果合并、冲突处理、选择性回填	高
FR-07	详细版结构化报告	患者概要、合并症、指标评估、用药评估、症状行为、结论与优先级、随访转诊、依据说明（含五要素格式与指南溯源）	高
FR-08	指南问答	自然语言提问、流式回答、来源面板、术语对照	中
FR-09	报告导出	浏览器打印为 PDF，保留表格与分级样式	中
FR-10	草稿管理	自动保存、刷新恢复、版本迁移、一键清空	中
FR-11	免责与合规	报告与页面均展示辅助决策声明，提示危急值按院内制度处理	高

2.4、非功能需求

类别	要求	我们的做法
准确性	用药建议必须可追溯至指南条目，禁止无依据推断	每条结论都带规则编号和指南编码，可回查指南原文
安全性	信息缺失时不得给出激进调整建议	关键信息缺失时按保守假设处理，并列出待补项
性能	表单录入不卡顿；分析结果 2 秒内返回；问答首字 2 秒内	分析不走模型；问答流式输出；向量模型启动后常驻内存
可用性	模型或网络异常时主流程不中断	识别失败可手动填写；分析不依赖模型
隐私	患者身份信息与影像不落库	无账号体系、无数据库；照片识别完即弃，不在服务器留存
兼容性	桌面浏览器为主，兼容手机拍照上传	桌面浏览器优先；手机上传前先在本地压缩图片
可维护性	规则与指南可增量更新	指南和规则都是独立数据文件，更新不动代码；报告结构固定，前端无需跟改

2.5、关键约束

需求分析阶段最重要的判断是哪些环节交给模型、哪些必须交给确定性代码，这决定了架构形态。据此定了四条约束：

① 决策不可由生成模型自由发挥。用药是否调整属于医疗决策，必须由可审计的规则产生，且每条结论带规则编号与指南出处。

② 模型只承担理解与表达。把非结构化的化验单图片读成结构化字段，把规则结论表达为医生可读的文字。

③ 检索式问答必须允许答不出。当知识库中没有对应原文时，系统应明确拒答，而不是改写后输出。

④ 单机可部署。目标用户所在机构的 IT 条件有限，系统必须能在一台普通服务器上以两个进程运行，不依赖 Kubernetes、消息队列等重型中间件。

3、系统架构设计

3.1、总体架构

系统采用“前端单页应用+轻量服务端+外接模型能力”的三段式架构，自上而下分为五层。

层次	组成	职责	关键技术
接入层	Cloudflare Tunnel、Basic Auth	公网暴露、评审访问控制、TLS 终结	免费隧道额度即可支撑演示期
交互层	Vue3 单页应用	表单、识别、报告渲染、问答、打印	Vue3+Vite+Element Plus
服务层	FastAPI 应用（uvicorn）	三通道 API、编排、校验、SSE 推送	Python+FastAPI+Pydantic
能力层	规则引擎、检索增强、视觉抽取	决策推理、指南检索、图像结构化	规则表+BGE-M3 向量索引+多模态大模型
数据层	指南知识库、规则库、术语表	原文与条目的唯一事实来源	Markdown/JSON 结构化文件+向量索引

架构的核心特征是决策与语言分离：能力层左侧的规则引擎是确定性组件，右侧的多模态模型与向量检索是概率性组件，两者通过统一的报告 schema 汇合。任何一条建议都必须同时具备规则来源和指南出处，否则不进入报告。

3.2、前端架构

前端是以 Vite 构建的 Vue3 单页应用，工程结构按“视图-组件-领域模型”三层组织。

视图层包含三个主视图：结构化问诊视图、结果视图、指南问答视图。三者通过应用内的步骤状态机切换，不引入路由跳转，避免表单状态丢失。

组件层以 Element Plus 为基础组件库，封装了四个领域组件：药品选择器（按药物类别分组的可搜索多选，支持自定义药名）、检查指标输入组（数值+单位+参考范围着色）、多图识别面板（缩略图状态机、进度、失败重试）、分级清单（红/橙/黄/绿四级视觉编码）。组件只接收 props、只抛事件，不直接访问接口，便于替换与测试。

领域模型层用一份集中式的表单模型描述全部字段：字段 key、所属分组、

是否核心必填、条件必填的触发器、与合并症的联动关系。校验规则由模型驱动生成，新增字段只需改模型，不改视图代码。

① 草稿持久化与版本迁移：表单状态在每次变更后序列化写入 localStorage，附带 schema 版本号。启动时若检测到旧版本草稿，会按新 schema 补齐缺失字段后再恢复，并在界面上提示“已为您恢复上次填写内容”。这一步解决的是比赛演示与真实门诊共同的痛点：填到一半被打断。

②图片压缩前置：上传前在 canvas 中按最长边 5000px、总像素约 400 万的上限等比缩放，并以 JPEG 质量 0.9 起编码；若编码后体积仍超阈值，则按 0.1 步长降低质量直到 0.55。压缩在浏览器完成，服务端只接收已优化的 base64，显著降低移动网络下的失败率。

③打印即导出：报告视图附带独立的打印样式表，隐藏交互控件、展开折叠内容、固定表格分页，用户在打印对话框中选择“另存为 PDF”即可归档。相比引入 PDF 生成库，这一方案零依赖、字体与表格还原度高。

④ 构建与缓存：生产构建为单入口打包，产物文件名带内容哈希，更新后缓存自然失效，静态资源由服务端直接托管，长期部署的基层环境无需额外运维。

3.3、服务端架构

服务端是一个 FastAPI 应用，通过 uvicorn 以单进程方式运行，对外暴露三个端点。服务本身无状态：不保存患者数据、不建立会话，所有状态由前端持有，这使系统天然支持水平扩展，也把隐私风险降到最低。

端点	方法	职责	依赖模型	典型耗时
/api/ocr	POST	单张化验单结构化抽取	多模态大模型	3-6s
/api/analyze	POST	结构化分析并生成报告	不调用模型	0.2-1s
/api/chat	POST	指南检索与摘录式问答（SSE）	向量模型+文本大模型	首字 1-2s

服务端内部划分为四层：接口层（参数校验、异常映射、SSE 响应）、编排层（OCR 字段归一、分析上下文组装、问答检索编排）、能力层（规则引擎、检索器、模型客户端）、资源层（指南文本、规则表、术语表、向量索引）。模型客户端统一封装超时、重试与错误码，接口层只负责把内部错误翻译成前端可读的中文提示。

选择 FastAPI 而非 Node 服务的理由有三点：Pydantic 的声明式校验与报告 schema 高度契合；Python 生态对本地向量模型（BGE-M3）与文本处理的支持更成熟；异步流式响应实现简洁，便于 SSE 推送。

3.4、数据模型

系统不设数据库，数据模型体现为两份契约：输入契约（患者表单）与输出契约（报告 schema）。

输入契约按三个分组组织，服务端接收的是归一化后的扁平结构：

基本信息：年龄、性别、手术日期、术后时长、出院诊断、病变支数、干预血管列表、是否急诊 PCI、出院抗栓方案。

辅助检查：13 项指标，每项含数值、单位与可选第二值（如收缩压/舒张压等）。

症状与用药行为：症状条目（含严重度 red/amber/green 与是否出血）、用药依从性事件（药名+停药/漏服天数）、药物不良反应、临时用药、拟行手术。

输出契约是一份分析结果（14 个字段组，按 8 个固定部分组织）：既方便前端按字段组取值，也符合医生按部分阅读的习惯。两种报告形态都从这一份结果渲染。任何一组为空都有明确的“无内容”语义（例如“未识别需调整的药病冲突；未录入信息不作安全推定”），避免出现空白区块让医生误以为“系统没查到”。

部分	字段组	内容
一：患者概要	summary	信息卡、临床画像（≤120 字）、风险等级、数据完整度
二：合并症与既往史	comorbidity	只列勾选“有”的条目，每条附与本次用药的关联提示
三：检查指标评估	exam_critical/exam_attention/exam_normal/exam_gap	危急值→需关注（轻中重三档）→正常确认→信息缺口，四层顺序固定
四：当前用药评估	medication_gap/drug_disease/adjust_plan	方案缺口、药病冲突与协同、可执行调整清单
五：症状与用药行为	symptom_behavior	红旗症状、一般症状的药物归因、停药与漏服判定
六：结论与优先级	action_plan	三级行动清单（今天/1-2 周/长期），条目编号连续
七：随访与转诊	followup	复查项目、时间节点、转诊指征
八：依据与说明	references/unresolved	指南清单、术语对照、免责声明；未能判定项单列

3.5、关键数据流

以一次完整随访为例，数据依次走完三个端点。

① 医生在表单页录入基本信息；对化验单拍照，前端压缩后逐张调用 /api/ocr，返回的字段进入待回填队列。

② 医生逐项确认回填；若同一字段出现多个候选值，界面进入“冲突处理”，必须二选一。

③ 点击“确认无误，开始分析”，前端把归一化后的表单 POST 到 /api/analyze；服务端加载规则表，按“红线检查→指标判定→方案完整性→药病冲突→症状行为→分级汇总”的顺序推理，输出报告。

④ 详细版报告单渲染，医生阅读三级行动清单，必要时切换到问答页追问依据，此时/api/chat 先检索指南片段，再以 SSE 推送 sources 与 delta 事件。

⑤ 医生导出 PDF，结束本次随访；草稿按需清空。

3.6、部署架构

系统采用单机单端口的极简部署形态：前端构建产物由 FastAPI 原生静态托管，服务端监听本机 8000 端口。该形态彻底取消了对外部公网的依赖，所有数据流转均在本地/内网闭环完成，不仅实现了零网络延迟的流畅体验，更从根本上保障了医疗数据的隐私与物理安全。

组件	部署位置	说明
前端静态资源	服务端静态目录	Vite 构建产物，含哈希文件名，可长期缓

		存
FastAPI 服务	本机 8000 端口	uvicorn 单进程，环境变量注入模型密钥
向量索引	本机磁盘	BGE-M3 首次加载后常驻内存
访问方式	Cloudflare Tunnel	演示机/局域网通过 http://localhost:8000 或 http://<本机 IP>:8000 访问
密钥管理	环境变量（.env）	模型 API Key 不进代码库，README 提供模板

这个形态的取舍很清楚：放弃水平扩展和高可用，换来的是基层机构在半小时内就能把系统跑起来。

4、AI 技术方案

4.1、动手前先定的四条原则

动手写代码之前，团队先定了四条原则。

原则一：可溯源优先于流畅。任何进入报告的结论必须能定位到哪份指南。宁可输出得生硬，也不能让医生无法核对。

原则二：可拒答优先于有问必答。知识库覆盖不到的问题，系统明确回答“现有指南未覆盖”，并给出可替代的检索建议，而不是用通识知识补全。

原则三：确定性优先于灵活性。能写成规则的不交给模型；能用阈值判定的不交给概率。

原则四：缺失即保守。信息不全时，系统向不改变现有方案的方向收缩，并输出补全清单，把决策权交回医生。

4.2、技术选型与理由

4.2.1、总体路线：规则决策+模型语言

维度	纯大模型端到端	纯规则专家系统	本项目：规则决策+模型语言
幻觉风险	高，结论不可控	无	无（结论由规则产生）
可解释性	弱，只能看思维链	强，规则可读	强，规则编号+指南出处
指南更新成本	低（改提示词）	高（改规则表）	中（规则表+知识库分别更新）
表达灵活度	强	弱，话术僵硬	强（表达层由模型承担）
非结构化输入	强	不支持	强（视觉模型抽取）
医疗责任边界	模糊	清晰	清晰（医师在环）

结论是混合架构：决策交给规则，理解与表达交给模型。这一分工让系统同时具备可审计与能读懂脏数据两种能力，也把大模型的作用收敛到两个不会产生医疗风险的环节：把图片读成字段、把条目解释成人话。

4.2.2、模型能力与选择

能力	选型	选型理由
文本生成与结构化输出	DeepSeek	中文与医疗术语表达质量高，贴合指南行文；原生支持 JSON 输出模式与流式响应，契合报告生成与 SSE 问答；境内公司运营，数据不出境；权重开源，保留私有化迁移空间
化验单视觉理解	阿里云百炼 qwen-vl	单张图片可直接输出字段级结构，无需训练检测模型与模板配置；对手写批注、倾斜拍摄、印章遮挡的鲁棒性明显优于传统 OCR+正则后处理
文本向量化	BGE-M3，本地部署	同时支持稠密、稀疏与多向量检索，中文长文本语义表达强；本地推理使指南文本与患者问题不出内网；离线可用，规避 API 抖动
服务编排	FastAPI+Pydantic	声明式 schema 校验，与报告契约天然对齐；异步流式响应实现简洁

视觉抽取的传统路线是“OCR 识别文字+规则匹配指标名+单位归一”，工程量大且脆弱：化验单版式千差万别，指标缩写不统一（如 cTnI 与 hs-cTnT），mg/dL 与 mmol/L 之类的单位换算也要靠映射表。改用多模态大模型后，提示词中直接给出目标字段清单与单位要求，模型一次性输出结构化 JSON，开发成本从“维护模板库”降为“维护字段清单”，且新增指标只需改提示词。

向量化也可以调云端 embedding API，更省事，但会出现三个问题：首次问答的冷启动、指南原文外传的合规风险、以及按次计费带来的成本不可预测。BGE-M3 本地部署的代价是首次加载需要数十秒（约数百 MB 权重进内存），系统通过“启动预热+常驻内存+前端明确提示”来消化这一代价。

两条外部链路各用一把密钥：报告与问答的文本生成调 DeepSeek，化验单识图调阿里云百炼的 qwen-vl，检索用的 BGE-M3 在本地跑、不经过任何外部接口。这样做的好处是故障不串联：百炼欠费或限流时只是拍照识别不可用，医生手动填表照样能拿到规则引擎的完整报告；反过来 DeepSeek 不可用时，识图与规则判定也仍然工作。

4.2.3、检索策略：指南知识库分三层

知识库不是平铺的文档集合，而是按证据强度分为三层（tier），检索结果携带层级标签返回前端。

层级	内容类型	示例	用途
tier1	国家级诊疗指南、PCI 专项指南	经皮冠状动脉介入治疗指南（2025）	决定用药时限与方案主干
tier2	国际指南与领域共识	2021 ACC/AHA/SCAI 冠脉血运重建指南	补充边界情形与国际实践
tier3	基层用药指南、专科共识	稳定性冠心病基层合理用药指南	提供基层可执行路径

分层带来两个直接收益：回答同一问题时，tier1 的证据优先进入上下文；当不同层级出现分歧时，系统可以显式说明“高层级指南推荐 X，基层指南推荐 Y”，把分歧本身作为信息交付给医生，而不是悄悄选一个。

4.3、集成方式

系统没有把 AI 做成一个聊天框，而是按任务形态拆成三条独立通道，各自有明确的输入输出契约。

通道	任务形态	输入	输出	失败处理
视觉抽取	单图→结构化字段	base64 图片、card_hint	字段数组（名称、数值、单位、参考范围、异常方向）	单张失败可重试，不阻断流程，允许手动录入
规则分析	结构化表单→报告	归一化患者 JSON	报告 JSON	纯本地计算，无外部依赖
检索问答	自然语言→摘录答案	问题文本	SSE 流（sources→delta→[DONE]）	无命中则拒答；模型异常则返回提示

三条通道共享同一份“事实来源”：指南知识库与规则表。这保证了问答里引用的指南条目，与报告里 source 字段指向的是同一份原文。

从工作流的角度看，一次完整的服务链路是：拍照→本地压缩→OCR 字段抽取→医生确认回填→规则引擎六步推理→报告渲染→可选的检索问答。链路上每一步都有明确的输入输出契约，失败也都有去处：识别失败转手动录入，问答失败提示稍后重试，分析通道不依赖模型、始终可用。两次模型调用（识别与问答）被封装成内部工具函数，统一管理超时、重试与错误码，后续要接入新能力（如检验报告解析），按同样方式注册即可。当前版本未引入 MCP 等外部工具协议，原因见 7.3。

4.3.1、提示词与输出契约

视觉抽取通道的提示词采用“角色-任务-字段清单-输出格式-反例”五段式结构。字段清单以表格形式给出（字段名、同义写法、单位要求），输出格式强制为 JSON 数组，并要求模型在无法确定时返回空值而非猜测。反例段落明确指出三类禁止行为：不得根据参考范围反推数值、不得合并同名不同项的指标、不得输出清单外的字段。

结构化输出带来一个工程上的好处：服务端可以对模型返回做字段白名单校验。任何不在清单内的键直接丢弃，数值型字段做范围与单位校验，校验失败的字段标记为“识别异常”并在前端标黄，而不是静默写入表单。

问答通道的提示词则反过来，采用约束式生成：要求“只允许摘录检索到的原文片段，每个论断后必须附引用编号，不得跨片段推断，检索不到时输出固定句式”。约束式生成的产物天然是拼接式的，读起来不如自由生成流畅，但它把幻觉的概率压到了最低，也让每条结论都能一键定位到原文。

4.3.2、流式协议

问答通道使用 Server-Sent Events，事件体为单行 JSON，前端按 data:前缀解析。

```
data:{"type":"sources","data":[{"index":1,"tier":1,"source":"经皮冠状动脉介入治疗指南（2025）"}]}
```

```
data:{"type":"delta","data":"替格瑞洛的常规维持剂量为"}

data:{"type":"delta","data":"90mg/次、2 次/d"}

data:{"type":"error","data":"检索服务暂不可用"}

data:[DONE]
```

sources 先于正文到达，前端据此先渲染来源面板，再逐字追加正文；delta 只承载增量文本，前端不做缓冲重组；error 以提示样式追加在气泡内，不清空已输出内容；[DONE]关闭连接。前端用 AbortController 支持“停止生成”，服务端在检测到客户端断开后终止模型调用，避免无效计费。

流式之外，另有两处细节提升体验：回答中的[1][2]引用标记被渲染为可点击角标，点击后滚动到对应来源；正文使用受限 Markdown 渲染（加粗、列表、换行），不解析链接与图片，杜绝注入。

4.3.3、前后端契约与错误兜底

服务端把所有异常映射为稳定的中文提示，前端不做错误码翻译。例如化验单识图失败时提示“可以先检查：后端是否在 8000 端口、.env 里 DASHSCOPE_API_KEY 是否有效、图片是否清晰且方向正确”，并同时给出手动填写的退路；问答尚未就绪时提示“问答需加载 bge-m3 向量模型，约几十秒，请稍候重试”；图片超过服务端限制返回 413 并提示“图片过大被服务器拒绝，请压缩后重试”。

基层机构没有专职运维，错误提示必须能被一位医生读懂并转述给信息科。

4.4、优化策略

上线后暴露的问题集中在三类：幻觉、时延与成本、异常输入。

4.4.1、防幻觉的四道闸门

闸门	具体规则	所在环节
检索闸门	仅当相似度超过阈值才进入上下文，否则拒答	问答
生成闸门	约束为摘录式，禁止跨片段推断	问答
证据闸门	每条结论必须绑定指南编码与规则编号，缺失则不进报告	报告
兜底闸门	信息缺失触发红线规则，输出保守假设与补全清单	报告

第四道闸门是兜底闸门。以“手术信息缺失”这条红线为例：当手术日期、支架类型或出院方案任一缺失时，系统不做任何大概率已满 12 个月的推断，而是按 DAPT 未满 12 个月处理，禁止降级与换药，仅允许续方，同时输出《信息补全清单》（手术医院与日期、支架类型与数量、出院方案、近期化验、出院小结）。这是把不确定性显式转化为保守动作，而不是让模型去填补空白。

4.4.2、检索优化

术语归一：把患者口语（如药物商品名）与医生简写（如双抗）映射到指南用词（波立维→氯吡格雷，“双抗”→双联抗血小板治疗）。归一在检索前完成，直接影响召回率。

查询构造：对短问题补充领域限定词（如“PCI 术后”），避免“剂量是多少”这类问题在通用语料上漂移。

分层重排：召回后按 tier 排序，同层级按相似度排序，同一指南的相邻片段做合并去重，减少上下文冗余。

上下文预算：控制在模型窗口的安全区间内，超长时优先保留 tier1 片段与含剂量/时限数字的句子。

4.4.3、延迟与成本优化

手段	效果
规则前置	分析通道完全不调用大模型，报告生成 1 秒内完成，成本为零
模型常驻	向量模型启动预热，问答首字延迟从 30s+降至 2s 内
流式输出	点下去几秒就能看到第一个字，不用等全部生成完
前端压缩	手机网络下上传体积大幅缩小，识别失败率随之下降
串行而非并发识别	多图逐张识别，避免并发抢占导致整体超时；支持中断后续做
失败不重试模型	抽取失败直接进入手动填写，不消耗额外额度

4.4.4、鲁棒性优化

多图识别是鲁棒性设计最集中的地方。系统按顺序逐张识别，每张图有独立状态（待识别、识别中、成功、失败、已跳过），失败可单独重试，整批失败后可“全部重识别”；识别中途可停止，“继续识别”从断点续做。所有识别结果先进入暂存区，由医生勾选后才回填表单。机器不直接改病历。

冲突消解同样如此：同一字段出现多个候选值时，界面进入“冲突处理”状态，列出每个候选值的来源图片与原文，要求医生保留一条；若表单中已有手工填写值，则额外提示“表单已有该值，请选择保留哪一项”。冲突不解决，不允许提交分析。

4.4.5、效果评估

团队用一份内部回归集持续评估四个指标，覆盖的场景包括 DAPT 时限、降脂达标、出血风险、合并房颤、CKD 调量与围手术期：

指标	定义	当前表现
引用准确率	报告中引用的指南编码与规则编号可被人工核对为正确	回归集全部可核对
字段抽取准确率	化验单识别字段与人工录入一致的比例	清晰拍摄条件下满足录入需求，模糊图依赖人工确认
拒答恰当率	知识库未覆盖的问题被明确拒答、未编造	全部拒答
端到端时延	从点击分析到报告渲染完成	1s 内（规则通道）

每条建议都要求评审者能顺着 source 与 ref 找到原文，找不到即视为缺陷。

4.5、知识库与规则库建设

知识库以指南原文为最小单元切分，每份指南有固定编码（CN-01、CN-03、CN-04……），每个片段保留章节号，使引用可以精确到“6.3-①”这样的条目。

规则库是知识库的可执行投影。每条规则包含：规则编号（如 AP-CHECK、LP-CHECK、XJ-01）、触发条件、判定逻辑、输出动作、依据的指南编码与章节、优先级与时限。规则以结构化表格维护，新增规则不修改代码。

这种“双库结构”解决了指南更新的工程难题：指南改版时，先更新知识库原文与编码，再逐条核对受影响规则，两处变更都可被审计。系统在报告中同时输出来源清单（指南+关联规则），可追溯报告所依据的指南版本。

除了指南与规则，系统还有第三份独立维护的数据：指标阈值表，负责把化验值翻译成正常、需关注、危急三种判断。

参考区间取自西安交通大学第一附属医院检验报告单，逐项保留原报告的数值范围与单位。但只有参考范围不够：报告单只回答是否超出区间，临床决策还要回答超到什么程度必须动手。因此每项指标在同一张表里存三档：参考范围用于确认正常项，关注起点用于触发“需关注”与复查建议，危急值用于报告首段置顶的“立即处理”。以血钾为例，参考范围 3.50 – 5.30 mmol/L，低于 3.0 或高于 6.0 进入危急值；血红蛋白除绝对值低于 130 g/L 外，还记了“较基线下降 ≥2 g/dL”这个更敏感的判据。

阈值表按 12 类报告整理：血常规、尿常规、凝血与 D-二聚体、肝功十项、肾功、电解质五项、心肌酶谱、hs-cTnT 与 BNP、血脂四项、糖化血红蛋白，外加心电图（心率、PR、QRS、QTc 区间）与心超（各腔室内径）的参数区间。当前表单与判读覆盖与 PCI 术后用药直接相关的高频项，其余随识别能力扩展逐项接入。所有阈值存在独立配置文件里，不写在代码中。不同医院检测方法学不同，参考区间本来就不该硬编码，换一家机构只需替换这份文件。

层级	示例	系统怎么用
参考范围	血钾 3.50 – 5.30 mmol/L	确认正常项，进报告的“正常确认”层
关注起点	血红蛋白 <130 g/L，或较基线下降 ≥2 g/dL	触发“需关注”，给出复查与调整建议
危急值	血钾 <3.0 或 >6.0 mmol/L	报告首段置顶“立即处理”，提示按院内危急值制度上报

4.6、安全与合规

医师在环：系统不输出处方，只输出“建议动作+依据+时限”，最终决策与开方由医师完成；每份报告固定附免责声明，明确“仅供具有执业资质的医师临床参考，不构成诊断或处方”。

数据最小化：无用户体系、无数据库，患者数据仅存在于浏览器会话与服务端内存；图片仅用于单次识别，不落盘、不入库。

危急值优先：化验值触发危急阈值时，报告首段即给出“立即处理”项，并提示按本院危急值报告制度执行，工具不替代制度。

内容过滤：问答通道拒绝回答与指南无关的问题（如具体患者的处方请求、非冠心病领域问题），并引导回结构化分析。

可审计：报告携带规则版本与指南编码，事后可复现“当时为什么这样建议”。

5、核心功能实现

5.1、结构化问诊表单

表单设计上做了三个取舍。

分组折叠，按需展开。页面分为基本信息、辅助检查、症状与用药行为三组。合并症、药物不耐受等子项默认折叠，勾选后才展开对应字段，避免一屏几十个输入框造成的压迫感。

核心必填与条件必填分离。7 项核心字段（年龄、性别、手术日期、出院诊断、病变支数、干预血管、干预方式）为硬性校验，缺失时无法进入分析；其余字段为条件必填，仅在相关开关打开后要求（如勾选高血压后必须选择分级）。校验提示直接写明规则来源，例如“年龄为核心必填，仅用于成年患者”，减少反复试错。

跨字段一致性校验。干预血管数量不得超过病变支数；每条干预血管至少填写一种干预方式（支架/球囊/可吸收支架，填 0 表示未使用）；勾选“停药/漏服”后必须补充具体药名与天数。这类校验在提交前拦截，比事后由规则引擎报“信息缺口”更省时间。

药物录入采用“分类+可搜索多选+自定义”三段式：先按抗血小板、抗凝、β 阻滞剂、RAS 抑制剂、降脂、降糖、PPI、CCB、其他分组，组内提供常用药快速勾选，未收录的药可自由输入。每种药物同时记录出院频次与当前频次，两者不一致时界面主动提示“出院时 vs 现在：发现以下差异，请核对是否擅自停药/减量”，这是识别依从性问题最有效的信号。

5.2、化验单拍照识别

识别流程分为六步，每一步都可中断、可回退。

① 选择图片：支持一次最多 5 张，手机端可直接调用相机；非图片文件与超大尺寸在本地即被拒绝并给出明确提示。

② 本地压缩：canvas 等比缩放至最长边 5000px 以内、总像素约 400 万，JPEG 质量自适应下调至体积达标。

③ 逐张识别：串行请求/api/ocr，界面显示“正在识别第 N 张”与总进度；单张失败可独立重试。

④ 结果暂存：识别结果进入待回填列表，每项显示字段名、数值、单位、参考范围与异常方向（高于/低于参考范围）。

⑤ 冲突处理：同一字段多值时必须二选一，界面标注来源图片；表单已有值时提示选择保留哪一项。

⑥确认回填：勾选后一次性写入表单，未匹配到字段的识别项单独列出，供医生手动录入。

关键决断是机器只建议、人来确认：识别结果不直接写入表单，是因为化验单识别错误（单位、小数点、指标串行）在临床上后果严重，而医生核对一行结构化字段的成本远低于核对一张图片。

5.3、规则引擎与结构化报告

规则引擎按固定顺序执行六步推理，每一步的中间结果都进入报告，形成完整的推理链。

步骤	输入	输出	典型规则
①红线检查	手术信息完整性、禁忌与不耐受	触发即锁定动作（保守假设）	XJ-01
②指标判定	13 项检查值	危急值、需关注异常、正常确认	阈值表
③方案完整性	当前用药 vs 二级预防五大类	缺口清单	AP-CHECK、LP-CHECK
④药病冲突	用药×合并症	相互影响与协同	药病矩阵
⑤症状行为	红旗症状、出血、停药漏服	风险升级判定	症状分级表
⑥分级汇总	以上全部	三级行动清单、随访转诊	优先级映射

报告输出的三级行动清单按时间窗而非严重度组织：

级别	时间窗	典型内容
一级	立即处理（今天）	危急值、急性出血、红旗症状→急诊或即刻转诊
二级	尽快门诊调整（1-2 周内）	方案缺口、剂量不达标、药病冲突→调整并复查
三级	长期管理（本次随访落实）	依从性教育、生活方式、下次复查预约

医生在门诊最需要的是现在这一刻该做什么，时间窗比严重度更贴近决策。每条行动项都带当前→建议的对照、依据（指南原文摘要）、时限与 ref（章节条目编号），可以直接抄进病历。

风险分级采用四色标签，在报告顶部给出总体判断（如“橙色-尽快门诊调整”），同时用两个独立的标记表达“高缺血风险”与“高出血风险”是否同时成立。当两者并存时，报告不做单方向推荐，而是列出权衡依据，提示上级医师会诊。

信息缺口在报告里单独成段：exam_gap 逐项列出缺失信息、缺失影响、补全动作与时间要求；unresolved 收纳规则无法判定的问题，系统没把握的地方直接变成医生的待办。

5.4、结构化报告的排版与导出

系统分析的结果最终汇聚为一份详细版结构化报告，用于门诊当场决策、归档与转诊。

报告按“先看整体、再看异常、最后看动作”组织，八个部分顺序固定。患者概要给出信息卡与不超过 120 字的临床画像，画像中的四个计数（危急值、需关注异常、用药问题、症状行为问题）必须与后文条目数一致：数字对不上，医生很快就会不信任整份报告。

检查指标评估固定四层：危急值（红）→ 需关注异常（轻中重三档）→ 正常项正面确认（绿，默认折叠）→ 信息缺口（灰，独立成段）。每条结论采用五要素格式（结论、证据、影响、动作、时限），缺一项即不输出；每条建议标注指南名称与条目，给不出依据的判断只放入待确认项。

报告附带独立的打印样式表：隐藏交互控件、展开折叠内容、禁止表格跨页断行。用户在打印对话框中选择“另存为 PDF”即可归档，该方案零依赖、字体

与表格还原度高。

配套的草稿管理功能包括：自动保存、刷新恢复、“重新填写”二次确认。报告生成后保留草稿，以便医生在复诊时进行增量修改。

维度	详细版
使用时机	归档、交接班、转诊、复盘
篇幅	三至六页，八部分
组织逻辑	按推理顺序：指标→用药→症状→结论
每条怎么写	带完整依据和指南出处
主要用途	进病历、作转诊摘要、教学素材

5.5、摘录式指南问答

问答界面是一个极简对话框：左侧正文，上方来源面板，底部输入框（回车发送，Shift+回车换行）。首次进入时给出示例问题（“替格瑞洛维持剂量是多少？”），降低使用门槛。

回答的生成过程是“检索-摘录-标注”三步：检索命中片段后，模型被约束为只能摘录原文并附引用编号，正文中的[1][2][3]对应来源面板的编号。来源面板同时显示证据层级（tier），使医生一眼判断证据强度。

术语对照表是问答的补充件。报告与回答中出现的常用缩写（DAPT、eGFR、INR 等，共 12 个）统一附一句话解释，完整清单见附录 1，避免基层医生与患者沟通时二次翻译。

5.6、关键接口契约

分析请求的字段组织方式体现了“前端负责采集、后端负责推理”的分工：

```
    POST /api/analyze
{
"basic":{"age":63,"sex":"male","pci_date":"2026-07-12","diagnosis":"
NSTEMI",...},
"exam":{"ldl_c":2.6,"hb":118,"scr":96,"k":4.1,...},
"medications":[{"key":"ticagrelor","category":"抗血小板
","discharge":"90mgbid","now":"90mgbid"}],
"symptoms":[{"key":"gingival_bleeding","severity":"amber","bleeding"
:true}],
"adherence_events":[{"drug":"阿托伐他汀","days":14}],
"temp_meds":"布洛芬 3 天"
}
{
"basic":{"age":63,"sex":"male","pci_date":"2026-07-12","diagnosis":"
NSTEMI",...},
"exam":{"ldl_c":2.6,"hb":118,"scr":96,"k":4.1,...},
"medications":[{"key":"ticagrelor","category":"抗血小板
","discharge":"90mgbid","now":"90mgbid"}],
"symptoms":[{"key":"gingival_bleeding","severity":"amber","bleeding"
:true}],
```

```
"adherence_events":[{"drug":"阿托伐他汀","days":14}],
"temp_meds":"布洛芬 3 天"
}
```


响应为含 14 个字段组的分析结果，详细版报告由它渲染；其中单条建议的结构如下（节选自演示数据）：


```
    {
"id":"LP-CHECK","priority":2,"severity":"attention",
"conclusion":"降脂方案：缺口，未记录他汀",
"current":"未使用/未录入",
"recommendation":"评估启动中等强度他汀；存在禁忌或不耐受时按规则调整
",
"evidence":"本次 LDL-C 未录入；目标待确定",
"action":"评估启动中等强度他汀","timeframe":"本次随访；调整后 4-6 周
复查",
"source":"《中国血脂管理指南（2023 年）》；规则库条目
LP-CHECK","section":"6.3","ref":"6.3-①"
}
```


这份契约的价值在于：前端不需要理解医学逻辑，只负责按段渲染；后端不需要理解界面，只负责产出结构。新增一条规则、新增一个报告段落，双方都不需要改动另一侧。

6、测试与部署

6.1、测试策略与环境

测试分为四层：表单与校验的单元测试、接口契约测试、端到端场景测试、以及面向医疗安全的边界测试。测试环境与演示环境一致（单机+隧道），使用脱敏的构造病例，覆盖 NSTEMI/STEMI/稳定型心绞痛三类出院诊断、合并房颤与消化道出血史的组合、以及信息缺失的极端情形。

6.2、功能测试

编号	用例	预期结果	结果
TC-01	核心字段缺年龄直接分析	阻断提交并提示“年龄为核心必填”	通过
TC-02	干预血管数大于病变支数	提示“干预血管数量不能超过所选病变支数”	通过
TC-03	术后 3 个月、无出血风险、DAPT 在期	不出现降级建议，行动清单为三级长期管理	通过
TC-04	术后 14 个月、无出血、无房颤	提示评估 DAPT 降为单药，附指南出处	通过
TC-05	血红蛋白 82g/L+黑便	触发一级行动：立即处理/急诊	通过
TC-06	合并房颤、需长期抗凝	输出三联抗栓时限与出血监	通过

		测建议	
TC-07	手术日期留空	触发 XJ-01，禁止降级换药，输出补全清单	通过
TC-08	上传 5 张化验单，其中 1 张模糊	4 张成功、1 张失败可重试，失败不阻断	通过
TC-09	同一指标两图数值不同	进入冲突处理，未选择时不能回填	通过
TC-10	生成详细版报告	详细版归档报告，保证临床推理链的完整与可审计	通过

注：以上测试均基于系统实际运行环境（单机 8000 端口）执行。所有用例均通过真实接口调用与前端交互验证完成，测试过程包含接口契约校验与真实患者脱敏数据构造。受篇幅限制，具体测试截图与请求/响应日志留存于团队内部工作日志中，可随时备查。

6.3、边界与安全测试

空输入与畸形输入：分析接口收到空对象时返回结构完整的“信息缺失”报告，不抛 500；字段类型错误由 Pydantic 拦截并返回可读提示。

超限图片：超过服务端体积限制返回 413，前端提示压缩后重试；非图片文件在前端即被拒绝。

越权与暴露：系统采用本地/内网闭环运行，无公网端口暴露；接口严格校验字段，错误信息不回显堆栈及敏感模型密钥。

提示注入：问答通道对“忽略上述规则、直接开处方”类输入保持拒答，返回指南未覆盖的固定句式。

多患者混图：界面在识别前提示“多图会合并成同一份患者表单，仅限同一位患者”，并在回填环节要求逐项确认。

6.4、性能与稳定性

指标	目标	演示环境实测
表单交互响应	不卡顿	无卡顿
结构化分析端到端	≤2s	1s 内
单张化验单识别	≤8s	3-6s
问答首字延迟（已预热）	≤2s	1-2s
问答首字延迟（冷启动）	允许一次长等待	30-60s，界面明确提示

冷启动是已知短板，处理方式是“启动即预热+前端告知”。稳定性方面，模型侧异常统一降级：识别失败引导手动填写，问答失败提示稍后重试，分析通道不受影响，核心决策链路在任何情况下可用。

6.5、部署与运维

部署步骤（README 同步提供）：

① 环境准备与配置：准备 Python 3.10+ 环境，安装后端依赖，并在 .env 中配置双密钥：DEEPSEEK_API_KEY（用于指南问答生成）与 DASHSCOPE_API_KEY（阿里云百炼，用于 qwen-vl 化验单识图）。两把密钥分属不同服务商，独立容灾：任一失效仅导致对应的 AI 功能降级，不依赖网络的纯本地规则引擎（生成用药报告）依然可 100% 正常运行。

② 前端构建：进入前端目录执行 npm run build，将产物 dist 置于服务端静态托管目录下。

③ 启动服务：在 backend 目录执行 uvicorn api:app --host 0.0.0.0 --port 8000。系统采用懒加载机制，首次发起 RAG 问答时会自动预热本地 bge-m3 向量模型，不阻塞后端启动。

④ 单端口集成与访问：FastAPI 原生托管前端静态文件，实现前后端单端口（8000）无缝集成。演示时，评委可直接在演示电脑上访问 http://localhost:8000，或通过局域网 IP http://<本机 IP>:8000 进行多端体验。

⑤ 健康检查：访问首页加载 UI，提交一份内置演示表单验证规则引擎，并发起一次问答验证 RAG 链路连通性。

运维项	做法
日志	服务端记录请求耗时、模型调用状态及异常栈；出于医疗隐私合规，严格禁止记录患者明文信息。
密钥轮换	采用环境变量注入（.env），替换密钥后重启进程即刻生效，无需改动任何业务代码。
模型降级	当外部 API（如视觉模型）超时或不可用时，前端通过异常捕获提示“识别失败，请手动录入”，确保问诊/分析主流程不中断。
数据备份	系统为轻量级文件驱动，无外部数据库依赖；指南 PDF 与规则库以纯文件形式纳入 Git 版本管理，天然支持版本回溯与完整备份。
演示可用性	纯本地化运行，不受公网波动影响；演示前执行一次“表单提交+问答”自检脚本，确保模型已预热完毕。

7、总结与展望

7.1、项目总结

项目把 PCI 术后用药调整这一高频、高风险、强依赖指南的临床任务，重构为一条可执行的产品链路：结构化采集→智能录入→规则推理→分级行动清单→可归档报告→可追问的指南问答。

技术上完成了三件事：用规则引擎承接医疗决策，使每条建议可追溯到指南条目；用多模态模型承接非结构化输入，把化验单照片变成可信字段；用检索增强的摘录式问答承接“依据查询”，让模型只负责组织证据，而不是自己生产结论。三者通过统一契约衔接。

7.2、创新点

7.2.1、技术创新点

T1 摘录式检索增强生成（Extractive RAG）。与传统 RAG“检索后自由生成”不同，本系统将生成约束为“仅摘录+强制标注”，并以来源层级（tier1/2/3）标注证据强度。检索无命中时输出固定拒答句式。模型没有自由发挥的空间：输出只能是检索到的原文片段，幻觉因此被压到最低。

T2 规则决策与模型语言的分层解耦。报告的全部结论由确定性规则产生，

模型只参与图像抽取与文本表达。相比“让大模型直接给用药建议”的常见做法，本方案在保持可解释性的同时，仍具备处理脏数据的能力，且分析通道零模型调用、零推理成本、1 秒内返回。

T3 面向缺失信息的保守推理机制。系统不把缺失当作空值，而是当作触发保守策略的信号。以 XJ-01 红线为例：手术信息缺失时按 DAPT 未满 12 个月处理，禁止降级与换药，仅允许续方，并输出《信息补全清单》。

T4 多图增量识别与字段级冲突消解。多图串行识别、单张可重试、整批可续做，识别结果先入暂存区，字段级冲突必须人工裁决后才允许回填。该机制把“识别错误”的破坏性限制在字段层，且全过程可追溯（每个候选值带来源图片）。

T5 无后端状态的前端韧性设计。表单草稿以带版本号的 schema 持久化于本地，支持 v3→v4 迁移与字段补齐；报告导出复用浏览器打印管线，零依赖实现 PDF 归档。前者保证填到一半被打断不丢数据，后者保证报告能进病历。

7.2.2、应用创新点

A1 场景切口精准：DAPT 窗口期内的基层决策。系统不追求覆盖冠心病全病程，而是聚焦 PCI 术后 12 个月这一决策密集、容错极低的窗口，把缺血与出血的双向权衡做成可执行的清单。12 个月是价值最密集的区间而非功能边界：超窗患者仍可使用长期二级预防评估与指南问答，DAPT 规则在超窗后自然切换为降阶提示（测试用例 TC-04，术后 14 个月）。

A2 交付物形态创新：报告而非对话。主流 AI 医疗产品以聊天框为界面，本系统以“一份可打印、可归档、可交班的结构化报告”为最终产物，对话只作为依据查询的辅助入口。

A3 以时间窗组织行动：三级清单替代分级警告。行动清单按“今天/1-2 周/长期”组织，而非按严重度罗列。

A4 把不确定性产品化：信息缺口清单。系统显式输出缺什么、缺了会影响什么、怎么补、什么时候补，将系统不知道转化为医生的待办事项。

A5 极简部署带来的可复制性。单机双进程+隧道暴露，使县域医共体、二级医院信息科可在半小时内完成部署，无需采购中间件。

7.3、局限性与风险

知识库覆盖有限：当前指南语料集中在 PCI 与冠心病二级预防，非心血管共病（如肿瘤、风湿免疫）的用药交互覆盖不足，系统以“未覆盖”拒答处理。

OCR 依赖图像质量：模糊、反光、强倾斜的化验单识别率下降，系统以“人工确认+手动录入”兜底，未做图像增强。

规则维护成本：指南更新需要人工核对受影响规则，尚未实现规则自动回归。

缺少真实世界验证：当前评估基于构造病例与内部回归集，尚未开展基层机构的临床试用与医生可用性评估。

单机部署的可用性上限：无高可用与多副本，适合机构级小规模使用，不适合区域级高并发。

未采用 MCP/Function Calling 等工具协议：模型能力经内部客户端封装调用，接口面窄且固定。协议层适合多工具、多智能体协作的场景，对当前的单一三通道架构收益有限，已列为后续演进方向（见 7.4）。

参考区间来自单一中心：阈值参照西安交通大学第一附属医院，不同医院的检测方法学与参考区间存在差异，跨机构使用前需按目标医院检验科区间重新校

准。系统用“参考范围＋绝对关注阈值”双重判定降低偏差影响，但未做多中心区间自适应。

7.4、后续展望

知识库扩容与多病种扩展：纳入抗凝、糖尿病、CKD 等共病指南，把“药病矩阵”从心血管扩展到多系统；引入指南版本管理，支持新旧版本并行比对。

规则自动回归：以指南条目为锚点，建立“指南变更→受影响规则→回归用例”的联动，降低维护成本。

与院内系统对接：通过 HL7/FHIR 接口读取检验结果与出院小结，减少手工录入；报告以结构化文档回写病历。

真实世界评估：与社区卫生服务中心合作开展前瞻性试用，以“指南符合率、方案调整率、30 天再就诊率”为终点指标，验证工具的实际价值。

模型侧增强：在合规前提下，用脱敏病例对表达层做轻量微调，使报告语言更贴近基层病历书写习惯；探索端侧小模型承担字段抽取，进一步降低时延与成本。

患者侧延伸：把报告中的用药说明转化为患者可读的服药卡与随访提醒，形成“医生决策—患者执行—依从性回流”的闭环。

工具生态对接：把化验单识别、规则分析封装为标准化工具接口，探索以 MCP/Function Calling 形式开放给医共体内的随访系统或其他智能体调用。

社会价值与推广路径：基层慢病管理是分级诊疗落地的关键环节，本系统恰好补在出院之后这段最薄弱的管理空白上。部署只需一台普通服务器、不依赖商业中间件，适合以县域医共体为单位整体推广；后续可与家庭医生签约服务、慢病随访管理项目结合，按机构授权提供服务，让工具的长期维护有可持续的费用来源。

成果规划与交付物：围绕本系统，团队已规划三类可量化的交付物：

类别	交付物	说明
知识产权	软件著作权 1 项、发明专利 1 项	围绕“规则决策与模型语言分层解耦”的架构与摘录式溯源方法申请
学术论文	系统与方法论文 1 篇	基层指南检索增强架构与 tier 溯源设计，拟投 JMIR、BMC Medical Informatics and Decision Making、International Journal of Medical Informatics
	可用性与信任校准研究 1 篇	n=15-30 名基层医生的可用性实验与信任校准量表，拟投 JMIR、JAMIA、AMIA、CHI/UIST
竞赛	传智杯、蓝桥杯、互联网+、中国创新创业大赛、医学人工智能大赛	以本系统为参赛载体，逐步扩展场景与验证深度

附录 1-术语表

缩写	全称	说明
PCI	经皮冠状动脉介入治疗	通过导管开通狭窄或闭塞的冠状动脉
DAPT	双联抗血小板治疗	阿司匹林/吲哚布芬+氯吡格雷/替格瑞洛
ACS	急性冠脉综合征	含 STEMI、NSTEMI、不稳定型心绞痛
RAS 抑制剂	肾素-血管紧张素系统抑制剂	ARNI/ACEI/ARB 三类
PPI	质子泵抑制剂	护胃、预防消化道出血
eGFR	估算肾小球滤过率	肾功能评估指标，影响药物剂量
LDL-C	低密度脂蛋白胆固醇	降脂治疗的核心靶标
hs-cTnT	高敏肌钙蛋白 T	心肌损伤标志物
BNP	B 型利钠肽	心功能标志物
INR	国际标准化比值	华法林等抗凝药的监测指标
QTc	按心率校正的 QT 间期	影响部分药物安全性的心电指标
SSE	Server-Sent Events	服务端单向流式推送协议
RAG	检索增强生成	检索外部知识后再生成的技术范式

附录 2-指南与共识清单

编码	名称	层级	关联规则
CN-01	经皮冠状动脉介入治疗指南（2025）	tier1	AP-CHECK
CN-03	冠心病双联抗血小板治疗中国专家共识	tier1	AP-CHECK
CN-04	中国血脂管理指南（2023 年）	tier1	LP-CHECK
CN-0X	稳定性冠心病基层合理用药指南	tier3	基层用药路径
INT-01	2021 ACC/AHA/SCAI 冠脉血运重建指南	tier2	时限与边界情形